

Quanto custa um alerta?

Avaliação Intermediária · Cibersegurança Aplicada com Inteligência Artificial · Insper 2026-2

Antonio Almeida e Luka Figueiredo · código d23bda · random_state = 3527138017 · classe difícil: DoS
slowloris + DoS Slowhttptest

Nota de método. Limpeza equivalente à do item e) do Roteiro 2: 6.313 linhas removidas (5,65%) e 18 colunas, restando 105.366×65 . Somadas as 5 features derivadas do item g) do Roteiro 2, **66 features** entram no modelo. Split temporal como o enunciado pede — dentro de cada dia, os primeiros 70% da `ordem_captura` treinam: treino 73.754 (prevalência de ataque 0,4282), teste 31.612 (0,3349). Esse corte deixa **oito das quinze classes fora do teste**, a difícil entre elas; o item c) usa um *split auxiliar* por (`dia`, `Label`) só para essa medida, sem alterar o modelo nem os arquivos de `saida/`. Convenção de decisão em todo o notebook: `p >= limiar` (os 102 empates em 0,5 contam como alerta, ao contrário de `predict()`). Na Parte B, `Time` fica fora das features.

1. Parte A — o seu detector de intrusão




Figura 1: b) pontuações do teste temporal por classe verdadeira, eixo y em escala log. O corte 0,5 (tracejado) encosta no pico benigno da quinta-feira.




Figura 2: c) curvas ROC e Precision-Recall no teste temporal. A referência do acaso é 0,500 na ROC e a prevalência, 0,3349, na PR.

b.1 — onde está a dúvida e o corte 0,5 cai em região vazia ou povoada?

O modelo é confiante na maioria dos casos — **75,6%** dos fluxos recebem pontuação exatamente 0 ou 1 — mas o corte 0,5 **não** passa por região vazia: **885 fluxos** (2,8%) estão na faixa $[0,45; 0,55]$. A zona de dúvida tem duas regiões de natureza oposta.

Um pico encostado no corte por baixo. A faixa $(0,45; 0,50]$ tem **686 fluxos**, dos quais **617 benignos**; os 69 ataques restantes são quase todos DoS GoldenEye (65). E esses benignos não estão espalhados: **608 dos 617 vêm da quinta-feira**, exatamente o dia em que a prevalência de ataque cai de 0,2030 no treino para 0,0050 no teste. A metade de treino daquele dia é dominada por **Web Attack** e **Infiltration**, tráfego HTTP parecido com navegação legítima; o modelo aprendeu uma fronteira difusa sobre o HTTP da quinta e, na metade de teste — quase toda benigna —, pontua esse mesmo tráfego perto de 0,47. No corte 0,5 esses 617 fluxos estão *corretos*,

por margem mínima: o risco não é o erro atual, é a fragilidade. Baixar o limiar para 0,45 os converteria em falsos positivos para recuperar 69 ataques — **9 alertas falsos por ataque**, quase todos de um único dia.

Um aglomerado de ataques bem abaixo. Entre 0,15 e 0,30 a composição se inverte: (0,15; 0,20] tem 298 ataques contra 94 benignos, e (0,20; 0,25] tem 308 contra 55. São ataques reconhecidos parcialmente que o corte descarta — falsos negativos por margem. Ao todo, [0,2; 0,8] contém **1.767 fluxos (5,59%)**: 934 benignos e 833 ataques.

O 0,5 é a pior posição possível dentro dessa distribuição: fica em cima do pico benigno, onde o custo marginal de baixar o limiar é máximo, e acima do aglomerado de ataques, onde estaria o ganho.

c.1 — as duas áreas contam a mesma história? Qual levar ao gestor do SOC?

ROC-AUC = 0,9961 e **PR-AUC = 0,9928** contam a mesma história. A prevalência de ataque no teste é **0,3349**, então a classe positiva não é rara — ROC e PR só se descolam quando os negativos superam a fila de alertas em ordens de grandeza, e aqui são 21.025 negativos contra 9.886 alertas no corte 0,5.

Levaria a **PR-AUC**, porque o seu denominador é a fila que o analista abre. E porque a prevalência de 33% é artefato da captura controlada: numa rede real ela cai ordens de grandeza, e nesse cenário a PR-AUC despenca enquanto a ROC-AUC quase não se move. Nenhuma das duas escolhe o limiar: são médias sobre todos os cortes, e o SOC opera em um só.

c.2 — o recall da classe difícil é compatível com o global?

Recall global em 0,5: **0,9179** (9.718 de 10.587). A comparação direta é impossível no split principal: DoS slowloris e DoS Slowhttptest **não têm linhas no teste**. A causa é o corte de 70% sobre a ordem_captura do dia inteiro: na quarta ele cai em 437.558, enquanto slowloris termina em 69.271, Slowhttptest em 74.859 e DoS Hulk em 330.978 — as três caem inteiras no treino. O mesmo elimina Bot, FTP-Patator e os três Web Attack: **treino com 14 rótulos, teste com 7**.

No split auxiliar por (dia, Label): slowloris **0,9960**, Slowhttptest **0,9024**, agregado **0,9501**, contra global de 0,9331 nesse mesmo split.

O limiar único falha mesmo no split principal: DDoS 0,9978 e SSH-Patator 0,9904 convivem com DoS GoldenEye **0,7025** e com Infiltration, Heartbleed e PortScan em **0,0000**. DDoS é 65% dos ataques do teste e domina a média. O GoldenEye explica o mecanismo: 65 dos seus fluxos estão na faixa (0,45; 0,50] do item b), ou seja, o **corte 0,5 atravessa a classe em vez de separá-la**.

d.1 — qual limiar maximiza o F1 e quantos falsos positivos a mais ou a menos?

Na grade de 0,05 o F1 máximo é **0,9521 no limiar 0,55**, contra 0,9493 em 0,50: são **−150 falsos positivos** (168 → 18), **+82 falsos negativos** (869 → 951) e **−232 alertas**. O número isolado engana, por dois motivos.

A curva de F1 é bimodal. Há um segundo máximo em **0,15, com F1 = 0,9513** — 0,0008 abaixo. Os dois pontos estão empatados pela métrica e são operacionalmente opostos: em 0,15 o recall é **0,9962** (40 ataques perdidos) com 1.041 FP; em 0,55 cai para **0,9102** (951 perdidos) com 18 FP. **O F1 trata como equivalentes um detector que deixa passar 40 ataques e outro que deixa passar 951**, porque pondera precisão e recall igualmente — escolha que nada tem a ver com o custo de um incidente.

A grade de 0,05 erra o pico. A malha fina mostra o F1 máximo em **0,53** (0,9524), não em 0,55. A causa é o degrau do item b): entre 0,49 e 0,51 os falsos positivos despencam de 360 para 84 — os 617 benignos da quinta-feira saindo da fila de uma vez. Um passo de 0,05 atravessa esse degrau sem enxergá-lo.




Figura 3: e) custo contra limiar, decomposto nas duas parcelas (escala log), e volume de alertas contra a capacidade do SOC. As duas linhas horizontais do painel direito nunca são cruzadas pela curva de alertas.

e.1 — qual limiar minimiza o custo e quanto economiza?

O custo mínimo é **R\$ 48.384 no limiar 0,05**, contra R\$ 2.174.516 em 0,50 e R\$ 2.377.716 em 0,55 (F1 máximo): economia de **R\$ 2.126.132 (97,8%)** sobre o corte padrão e **R\$ 2.329.332 (98,0%)** sobre o F1 máximo.

A razão C_{FN}/C_{FP} é de **208 para 1**: um ataque perdido custa o equivalente a 208 alertas falsos, e com esse preço quase qualquer volume de triagem se paga. Em 0,05 os 2.157 falsos positivos custam R\$ 25.884 e os 9 ataques perdidos custam R\$ 22.500 — **as duas parcelas se equilibram, e é isso que caracteriza o ótimo**. Em 0,55, a economia de R\$ 25.668 em triagem é comprada ao preço de 942 ataques a mais passando, ou R\$ 2.355.000.

O F1 máximo é o pior dos três. Ele pondera precisão e recall igualmente, o que equivale a assumir $C_{FP} = C_{FN}$ — hipótese que este cenário contradiz por duas ordens de grandeza.

e.2 — o custo mínimo respeita a capacidade? E se o FN custar cinco vezes mais?

Não, e nenhum limiar respeita. A capacidade é de **3.161 alertas** (10% dos 31.612 fluxos). O limiar de custo mínimo gera **12.735 alertas, 4,0× a capacidade**. Mas o problema não é o limiar: mesmo em **1,0**, o corte mais conservador possível, o modelo ainda emite **7.848 alertas, 2,5× a capacidade**, com recall de 0,7412. A coluna `cabe_capacidade` é falsa nas 19 linhas da grade, e a malha fina de 0,95 a 1,00 confirma: **não existe “menor custo dentro da capacidade” neste cenário**.

A causa é estrutural — a prevalência de ataque no teste é **33,5%**, ou seja, há 10.587 ataques reais num período em que o SOC só tria 3.161 eventos. Mesmo um detector perfeito, com zero falsos positivos, estouraria a capacidade em 3,3×. O gargalo não é a precisão do modelo, é o dimensionamento do time.

Recomendação: operar em **0,05** e tratar a capacidade como decisão de gestão. Os números sustentam a conta: o excedente de 9.574 alertas custaria **R\$ 114.888** para ser triado a R\$ 12 cada; deixá-lo virar fila custaria **R\$ 19.880.992**, porque 83,1% desses alertas são ataques reais que ficariam sem resposta. **Absorver o excedente é 173× mais barato que ignorá-lo** — na prática, automação de triagem ou um segundo estágio de classificação, não mais analistas na proporção necessária.

Sensibilidade. Com C_{FN} 5× maior (R\$ 12.500) **a decisão não muda**: o ótimo continua em 0,05 e o custo sobe para R\$ 138.384, porque o ótimo já saturou na ponta baixa da grade. O ponto de virada está no sentido oposto — o limiar só sobe quando C_{FN} cai abaixo de $\sim$ R\$ 1.000 ($83\times C_{FP}$), indo a 0,10; abaixo de $\sim$ R\$ 250 vai a 0,15; e só com $C_{FN} = C_{FP}$ o ótimo salta para 0,55, coincidindo com o F1 máximo. Qualquer estimativa de custo de incidente acima de R\$ 1.000 leva ao mesmo limiar.

f.1 — qual estimativa é mais otimista e qual descreve a semana que vem?

A **validação cruzada**: PR-AUC **0,9987 $\pm$ 0,0003** contra **0,9928** do split temporal (otimismo +0,0059); ROC-AUC **0,9994 $\pm$ 0,0001** contra 0,9961 (+0,0032). O mecanismo é o embaralhamento — cada fold sorteia exemplos ao longo de toda a captura, e o modelo treina com o fim de uma campanha para ser testado no seu início. O desvio padrão minúsculo confirma: os cinco folds são o mesmo problema. **O número que descreve a semana que vem é o temporal, 0,9928.**

O **otimismo agregado é desprezível**, e é aí que está a **armadilha**. O recall por classe, medido nos dois regimes, desmente a leitura tranquilizadora:

classe	recall na CV	recall temporal	queda
Bot	0,9701	0,1486	0,8214
Web Attack - Sql Injection	0,9524	0,5714	0,3810
Heartbleed	1,0000	0,7500	0,2500
DoS Slowhttptest	0,9988	0,9024	0,0964
DoS Hulk	0,9960	0,9018	0,0941
DoS slowloris	0,9976	0,9960	0,0016

O Bot cai de **0,9701 para 0,1486** — queda de **0,8214**, cento e quarenta vezes o movimento da PR-AUC agregada. É o mesmo efeito do Roteiro 2 (lá, 0,96 $\rightarrow$ 0,16), agora reproduzido sobre o split temporal deste notebook em vez de apenas citado. Ele some na média por aritmética: as três classes que perdem mais de 0,10 de recall somam **4,7% dos ataques**, e a área é dominada pelos 95% restantes. Note ainda a assimetria *dentro* da classe difícil: **slowloris** praticamente não sofre (0,0016), enquanto **Slowhttptest** perde 0,0964 — duas campanhas do mesmo dia, da mesma família, com resistências diferentes ao drift.

O número oficial é a **PR-AUC temporal, 0,9928**, e ele **precisa vir com o recall por classe**: o envelhecimento do detector não aparece na área, acontece uma família por vez, e a primeira a ir é a de baixo volume — justamente a que a média protege da vista.

2. Parte B — fraude em cartão: Random Forest contra XGBoost

Split temporal por Time: treino 199.364 (384 fraudes, prevalência 0,00193), teste 85.443 (108 fraudes, 0,00126). 29 features: V1-V28 e Amount; `scale_pos_weight` = 198.980/384 = 518,18.




Figura 4: f) as áreas agregadas quase não se movem entre os dois regimes, enquanto o recall por classe desaba. A linha tracejada marca a queda da PR-AUC agregada, 0,0059.

g.1 — as duas áreas ordenam os modelos da mesma forma?

Não — elas se contradizem, o caso previsto para classes raras: Random Forest dá ROC-AUC 0,9376 e PR-AUC 0,8237; XGBoost dá ROC-AUC 0,9797 e PR-AUC 0,8113. A explicação está nos denominadores. Com 85.335 legítimas contra 108 fraudes, os 10 falsos positivos do XGBoost e o 1 do Random Forest são indistinguíveis de zero na taxa de falsos positivos — a ROC do XGBoost é melhor porque ele ordena melhor o *grosso* dos negativos, algo que ninguém no time de fraude percebe. Já a precisão tem o número de alertas no denominador: em 78 e 93 alertas, 10 FP contra 1 são 9 pontos percentuais (0,893 contra 0,987), pagos por clientes com a compra travada.

Mas escolher um modelo por uma diferença de 0,0124 num teste com 108 fraudes exige saber se ela sobrevive à reamostragem. Bootstrap pareado, 1.000 repetições sobre as mesmas linhas para os dois modelos:

diferença (RF – XGB)	observada	IC 95%	P(RF > XGB)
PR-AUC	+0,0124	[−0,0113; +0,0389]	0,836
ROC-AUC	−0,0421	[−0,0674; −0,0206]	0,000

O resultado é desconfortável e instrutivo. A única diferença estatisticamente sólida entre os dois modelos é a da ROC-AUC — e ela aponta para o XGBoost, na métrica que não serve para este problema. Na PR-AUC o intervalo cruza o zero: o Random Forest fica à frente em 83,6% das reamostragens, longe dos 97,5% que autorizariam afirmar vantagem.

A resposta honesta é: usaria a PR-AUC, mas ela não decide sozinha aqui. Ela impede a conclusão errada — escolher o XGBoost porque ordena melhor 85.335 transações que ninguém vai olhar — mas não tem resolução para separar os dois modelos com 108 fraudes. Quem decide é o item h), em reais: lá a diferença entre as combinações é de R\$ 2.019,25.

g.2 — no corte 0,5, os dois modelos erram do mesmo jeito?

Não: erram de formas opostas com total quase idêntico. O Random Forest é conservador — FP = 1, FN = 31, TP = 77, recall 0,7130, precisão 0,9872 — emitindo um único falso positivo em 85.335 legítimas e pagando com 31 fraudes perdidas. O XGBoost é agressivo — FP = 10, FN = 25, TP = 83, recall 0,7685, precisão 0,8925: o `scale_pos_weight` de 518,18 empurra as pontuações positivas para cima e ele captura 6 fraudes a mais ao preço de 9 falsos positivos a mais. Em erros totais, 32 contra 35; qual é melhor depende do preço de cada um — 9 FP custam R\$ 45, e 6 fraudes podem custar de R\$ 0 a R\$ 25.691. Nenhum dos dois produz pontuação exatamente 0,5 aqui, então `predict()` e `p >= 0,5` coincidem e a comparação não depende da convenção de desempate (ao contrário da Parte A, com 102 empates no corte).

h.1 — qual combinação de modelo e limiar minimiza o custo?

Random Forest no limiar 0,15, com R\$ 2.636,48, contra R\$ 4.655,73 do mesmo modelo em 0,5 (economia de R\$ 2.019,25, ou 43,4%), R\$ 2.825,96 do XGBoost em 0,5 e R\$ 2.820,96 do XGBoost no seu ótimo (0,70). O Random Forest no corte padrão é o pior dos quatro cenários: sua postura conservadora é a errada quando o FP custa R\$ 5 e o FN custa o valor da transação. Baixar o limiar para 0,15 converte conservadorismo em recall — os FP sobem de 1 para 20 (R\$ 95 a mais de fricção) e as fraudes perdidas caem de 31 para 23, recuperando R\$ 2.114,25.

O ótimo da grade é mesmo o ótimo? Em passos de 0,01 o mínimo real está em 0,18, com R\$ 2.616,48 — apenas R\$ 20,00 abaixo. A malha fina revela um degrau: entre 0,18 e 0,19 o custo salta de R\$ 2.616 para R\$ 2.839, porque uma única fraude de pouco mais de R\$ 200 cruza o corte. Essa é a escala real da decisão.




Figura 5: h) custo dos dois modelos com FN = valor da fraude e FP = R\$ 5,00. i) falsos positivos por 1.000 legítimas por hora, com IC 95% de Wilson.

A recomendação é robusta ao preço do falso positivo, a hipótese mais frágil do cenário: varrendo de R\$ 1 a R\$ 100 por alerta, o **Random Forest** vence em toda a faixa, com limiar ótimo em 0,10 (R\$ 1), 0,15 (R\$ 2 a R\$ 10) e 0,30 (R\$ 20 a R\$ 100). A conclusão só mudaria se o preço do alerta estivesse errado por um fator de quatro ou mais.

h.2 — o limiar de custo mínimo coincide com o de F1 máximo?

Para o **Random Forest**, não: custo mínimo em 0,15, F1 máximo em 0,30 — diferença de R\$ 144,48. Para o **XGBoost** os dois coincidem em 0,70, o que mostra que a coincidência é acidental, não uma propriedade. O `describe()` do `Amount` dos falsos negativos explica: em 0,15 são 23 fraudes perdidas somando R\$ 2.536,48 (mediana R\$ 7,59, média R\$ 110,28, máximo R\$ 1.096,99); em 0,30 são 25 somando R\$ 2.775,96 (mediana R\$ 7,59, média R\$ 111,04, mesmo máximo). As distribuições são quase idênticas em forma; o que muda são **duas fraudes, que valem R\$ 239,48**. Para o F1 elas valem o mesmo que qualquer outra, porque ele conta *unidades*: subir de 0,15 para 0,30 elimina 19 falsos positivos e melhora a precisão, e a métrica registra ganho. Em reais, esses 19 FP valiam R\$ 95,00 contra R\$ 239,48 das duas fraudes — prejuízo líquido de R\$ 144,48. A distribuição do `Amount` é fortemente assimétrica (mediana R\$ 7,59, média R\$ 110, máximo R\$ 1.097), e é essa assimetria que separa as métricas: o F1 otimiza a contagem, o custo otimiza a soma.

i.1 — os erros são uniformes? Quem paga a conta dos falsos positivos?

Por valor, a resposta exige cuidado estatístico. O recall global é 0,7870, e por quartil de `Amount`:

quartil	faixa de Amount	fraudes	recall	IC 95% (Wilson)	perda não detect.
Q1	R\$ 0,00 – 5,00	54	0,8148	[0,692; 0,896]	R\$ 14,32
Q2	R\$ 5,01 – 20,00	11	0,4545	[0,213; 0,720]	R\$ 72,30
Q3	R\$ 20,01 – 72,16	10	0,8000	[0,490; 0,943]	R\$ 65,00
Q4	R\$ 72,18 – 25.691,16	33	0,8485	[0,691; 0,934]	R\$ 2.384,86

O Q2 marca 0,4545, bem abaixo dos demais — mas são **5 acertos em 11 fraudes**, com intervalo de Wilson de 0,213 a 0,720. O intervalo do recall global é [0,701; 0,854]. **Os dois se tocam**, ainda que por pouco: a diferença **não é estatisticamente distinguível**, e reportá-la como “o modelo falha entre R\$ 5 e R\$ 20” afirmaria mais do que os dados sustentam. O que se pode dizer é que há um **signal** a vigiar, plausível por um mecanismo conhecido — é ali que o fraudador testa o cartão antes do golpe grande, e o custo não está nos R\$ 72,30 perdidos, mas na fraude maior que o teste habilita depois. A recomendação é **monitorar esse quartil com amostra maior**, não recalibrar com base em 11 casos. O fato sólido sobre valor é outro: o **Q4 concentra R\$ 2.384,86 das R\$ 2.536,48 perdas (94%)**.

Por hora, o viés sobrevive ao teste. A média global é **0,234 FP por 1.000 legítimas** (20 em 85.335) e a hora 22 marca **0,929**, quatro vezes a média. A incerteza também é grande — 6 falsos positivos — mas o intervalo de Wilson da hora 22, **[0,426; 2,026]**, fica **inteiramente acima** da média global. É a única hora para a qual isso vale, e basta: **a diferença não é artefato de amostra pequena**.

Quem paga a conta **não são todos os clientes, é um grupo específico**: quem transaciona tarde da noite. Como o volume legítimo cai à noite (6.458 transações na hora 22 contra 8.659 na hora 16) e a fração de fraude sobe, o modelo aprendeu que “tarde da noite” é sinal de risco e transfere o atrito para uma faixa horária — o *erro desigual* da literatura, invisível em relatórios que só reportam a média.

i.2 — três limitações que impedem generalizar para um banco brasileiro hoje

1. Origem e período: dois dias de 2013, de uma adquirente europeia. O dataset cobre 48 horas de setembro de 2013, e nosso teste é mais estreito ainda — os 30% finais cobrem apenas as **horas 12 a 23 de um único dia**. Toda a análise horária acima mede meio dia: não há madrugada nem manhã, e o “padrão horário”

aprendido pode ser o perfil daquela tarde. Treze anos depois o mix brasileiro é outro (PIX, carteiras digitais, parcelamento, fração muito maior de cartão não presente), e a prevalência de 0,17% é um parâmetro daquele adquirente naquele mês — justamente o parâmetro que define a PR-AUC de referência e todo o cálculo de custo.

2. As features V1–V28 são componentes de PCA anônimos. Não se sabe o que medem, com três consequências: o modelo é *irreplacável* (não há como calcular V1–V28 no fluxo de outro banco sem a matriz original, não distribuída); é *inauditável* (não se explica a um cliente, ouvidor ou regulador por que a compra foi negada, o que colide com o direito à explicação sobre decisões automatizadas da LGPD, art. 20); e não se pode *verificar vies* — se alguma componente carrega informação correlacionada a região, renda ou tipo de estabelecimento, não há como detectar. Não à toa, o único vies que conseguimos evidenciar veio de `Time` e `Amount`, as duas colunas não transformadas.

3. Os rótulos vêm de contestação do cliente, não de verdade observada. Uma transação é “fraude” porque alguém a contestou e a contestação foi aceita. Fraude não percebida — valores baixos, cartões pouco usados, portadores idosos — está rotulada como *legítima*, e o modelo aprende a não vê-la. O vies é sistemático e aponta na mesma direção do ponto cego do Q2: R\$ 5–20 é onde a fraude menos é contestada e onde o recall é pior. Não há como separar limitação do modelo de rótulo faltante com estes dados, e por isso qualquer recall aqui é um limite superior otimista sobre a fraude real.

3. Parecer ao gestor do time de fraude

250 palavras, conforme o limite do enunciado; a contagem é verificada por asserção no próprio notebook.

Recomendação: Random Forest (`class_weight="balanced_subsample"`, `min_samples_leaf=2`) no limiar **0,15**, não no 0,5 padrão.

Modelo. O XGBoost tem ROC-AUC melhor, mas com prevalência de 0,126% a ROC é dominada pelas 85.335 transações legítimas e não enxerga a fila de alertas. Pela PR-AUC, cujo denominador é o número de alertas, o Random Forest fica à frente — embora o bootstrap mostre que essa vantagem não se distingue de ruído. Quem decide é o custo.

Limiar. No corte 0,5 o modelo custa **R\$ 4.655,73** no período; em 0,15 custa **R\$ 2.636,48**, economia de **43,4%**. A troca é barata: 19 falsos positivos a mais (R\$ 95 de fricção) recuperam R\$ 2.114,25 em fraude. O limiar de F1 máximo custaria R\$ 144,48 a mais, porque o F1 conta erros e aqui eles valem de R\$ 0 a R\$ 1.097. A recomendação não muda se o custo do falso positivo for de R\$ 1 a R\$ 100.

Volume. 105 alertas em 85.443 transações, 1,23 por 1.000 — cabe em qualquer triagem.

Recall. 0,7870 global. A faixa de R\$ 5 a R\$ 20 cai a 0,4545, mas com 11 fraudes o intervalo é largo demais para tratar como fato: é sinal a vigiar.

Validação. Reportar sempre split temporal; validação cruzada embaralhada é otimista.

Monitorar: custo semanal contra os R\$ 2.636 previstos; recall por quartil de `Amount`, com alarme se a pior faixa cair abaixo de 0,40 em amostra maior; falsos positivos por 1.000 legítimas por hora, hoje 0,234; deriva da prevalência; e recalibração mensal do limiar.